

SISREC

Implementação de um Sistema de Recomendação Híbrido

Maria João Pacheco (1250535)

Jorge Cruz (1221715)

Eduardo Caetano (1250509)

Mestrado em Engenharia Informática - Engenharia de Dados
Instituto Superior de Engenharia do Porto

Abril 2026

Conteúdo

1	Introdução	3
2	Estado da Arte na Área do Domínio Escolhido	4
2.1	Filtragem colaborativa	4
2.2	Sistemas baseados em conteúdo	4
2.3	Sistemas híbridos	5
2.4	Recomendação em e-commerce de eletrônica	5
2.5	Enquadramento do presente projeto	5
3	Especificação Técnica do Dataset	6
3.1	Estrutura lógica dos dados	6
3.2	Pré-processamento e integração	7
3.3	Adequação do dataset ao problema	8
4	Arquitetura do Sistema	8
4.1	Visão geral da arquitetura	8
4.2	Camada de persistência	9
4.3	Camada de integração de dados	9
4.4	Camada de serviços Web API	10
4.5	Camada de apresentação	10
4.6	Justificação da arquitetura	10
5	Sistema de Recomendação Não Personalizado	10
5.1	Motivação da baseline	10
5.2	Critério de ranking	11
5.3	Vantagens e limitações	11
6	Sistema de Recomendação Baseado em Conteúdo	12
6.1	Representação dos produtos	12
6.2	Vetorização com TF-IDF	12
6.3	Cálculo de similaridade	13

6.4	Papel da categoria e das subcategorias	13
6.5	Construção do perfil do utilizador	13
6.6	Vantagens e limitações	13
7	Filtragem Colaborativa	14
7.1	Princípio de funcionamento	14
7.2	Implementação	14
7.3	Vantagens e Limitações	15
8	Sistema de Recomendação Baseado em Conhecimento	16
8.1	Princípio de funcionamento	16
8.2	Implementação	16
8.3	Vantagens e Limitações	17
9	Sistema de Recomendação Híbrido	17
9.1	Princípio de funcionamento	17
9.2	Implementação	18
9.3	Vantagens e Limitações	19
10	Cold Start de Utilizadores	19
11	Cold Start de Itens	20
12	Avaliação dos Modelos de Recomendação	20
12.1	Estratégia de avaliação	20
12.2	Métricas de avaliação	21
12.3	Resultados	22
12.4	Discussão	22
12.5	Limitações da avaliação	24
12.6	Discussão	24
13	Conclusão	25

1. Introdução

Os sistemas de recomendação desempenham atualmente um papel fundamental nas plataformas digitais modernas, permitindo sugerir produtos relevantes aos utilizadores com base nas suas preferências, interações e padrões de comportamento. Em ambientes de comércio eletrónico, onde existe uma grande quantidade de produtos disponíveis, estes sistemas tornam-se essenciais para reduzir a sobrecarga de informação e melhorar a experiência de navegação do utilizador através da apresentação de recomendações mais relevantes e personalizadas.

O domínio selecionado para este projeto corresponde ao de produtos eletrónicos, recorrendo a dados derivados do dataset Amazon Electronics. Este domínio revela-se particularmente adequado para sistemas de recomendação, uma vez que os produtos possuem metadata rica, incluindo categorias, descrições, preços, classificações e reviews. Para além disso, o dataset inclui interações explícitas entre utilizadores e produtos sob a forma de ratings, permitindo explorar mecanismos de personalização das recomendações.

O principal objetivo deste projeto consiste no desenvolvimento de um sistema de recomendação híbrido suportado por uma arquitetura baseada em Web API. A solução implementada combina duas abordagens complementares. A primeira corresponde a um sistema de recomendação não personalizado, baseado na popularidade global dos produtos e na média das classificações atribuídas pelos utilizadores, sendo particularmente útil em cenários de cold start. A segunda corresponde a uma abordagem de Content-Based Filtering, onde as recomendações são geradas com base na similaridade entre produtos e nas interações previamente realizadas pelos utilizadores.

O sistema foi desenvolvido utilizando Python, FastAPI, SQLite e Scikit-learn. A similaridade entre produtos é calculada através de técnicas de engenharia de características, combinando processamento de categorias, normalização de atributos numéricos e cálculo de similaridade do cosseno entre vetores representativos dos produtos. O sistema permite gerar recomendações personalizadas de forma dinâmica a partir dos ratings atribuídos pelos utilizadores, mantendo simultaneamente recomendações não personalizadas para utilizadores sem histórico de interação.

Para além do motor de recomendação, o projeto inclui funcionalidades de gestão de utilizadores, mecanismos de atribuição de ratings, integração com base de dados relacional e uma interface frontend simples capaz de comunicar com os diferentes endpoints disponibilizados pela API.

Este relatório encontra-se organizado da seguinte forma. A Secção 2 apresenta o enquadramento teórico e os principais conceitos relacionados com sistemas de recomendação. A Secção 3 descreve o dataset utilizado e o processo de pré-processamento dos dados. A Secção 4 apresenta a arquitetura do sistema e os detalhes de implementação. As Sec-

ções 5 e 6 descrevem, respetivamente, o sistema de recomendação não personalizado e o sistema baseado em conteúdo. A Secção 7 apresenta a estratégia híbrida adotada e os mecanismos de tratamento de cold start. Por fim, as Secções 8 e 9 apresentam a avaliação experimental, discussão dos resultados e conclusões do trabalho.

2. Estado da Arte na Área do Domínio Escolhido

Os sistemas de recomendação podem ser organizados em três grandes famílias: filtragem colaborativa, filtragem baseada em conteúdo e sistemas híbridos. Esta taxonomia continua a ser a base conceptual da área, mesmo em trabalhos mais recentes que integram técnicas de *deep learning*, grafos ou modelos multimodais [1, 2, 3].

2.1. Filtragem colaborativa

A filtragem colaborativa é uma das abordagens mais utilizadas em sistemas de recomendação, baseando-se na premissa de que utilizadores com comportamentos semelhantes tendem a ter preferências semelhantes. Esta técnica utiliza interações históricas, como avaliações, para identificar padrões e prever preferências futuras.

A principal vantagem desta abordagem é a capacidade de capturar preferências implícitas sem depender diretamente da descrição dos itens. No entanto, a literatura identifica dois problemas clássicos. O primeiro é o cold start, que ocorre quando um novo utilizador ou um novo item não possui histórico suficiente. O segundo é a sparsity, isto é, a existência de poucas interações observadas face ao número total possível de combinações utilizador-item [1, 4, 7]. Estes desafios tornam-se particularmente relevantes em datasets de e-commerce com muitos produtos e poucas avaliações por item.

2.2. Sistemas baseados em conteúdo

Nos sistemas baseados em conteúdo, as recomendações são geradas a partir das características dos próprios itens e do perfil do utilizador. Em termos gerais, o sistema identifica os atributos dos produtos que o utilizador interagiu anteriormente e recomenda novos itens com representação semelhante [2].

Esta abordagem é especialmente apropriada em domínios onde os itens possuem descrição rica, como acontece em comércio eletrónico de produtos eletrónicos. Neste tipo de cenário, atributos como *nome do produto*, *categoria*, *descrição*, *preço*, *desconto* e *reviews* podem ser utilizados para construir uma representação vetorial dos produtos. A grande vantagem é a menor dependência de outros utilizadores, o que atenua o problema de *cold start* para itens e permite gerar recomendações mesmo com poucas interações históricas [2].

Em contrapartida, a literatura aponta limitações ao nível da diversidade, uma vez que o sistema tende a sugerir itens demasiado semelhantes aos já consumidos. Ainda assim, para contextos com elevada sparsity ou forte disponibilidade de metadata dos produtos, esta abordagem continua a ser uma escolha natural [2, 4].

2.3. Sistemas híbridos

Os sistemas híbridos combinam duas ou mais abordagens de recomendação para beneficiar dos pontos fortes de cada uma e reduzir as respetivas limitações. Burke [3] descreve várias estratégias de hibridização, incluindo *weighted*, *switching*, *cascade* e *mixed hybrid*. Em cenários reais, os sistemas híbridos são frequentemente apontados como soluções mais robustas, sobretudo quando se pretende equilibrar personalização, diversidade e cobertura.

Embora o presente projeto se concentre, nesta fase, numa baseline não personalizada e numa abordagem baseada em conteúdo, a literatura justifica claramente uma evolução futura para uma solução híbrida. Essa evolução torna-se particularmente relevante quando existe simultaneamente informação de conteúdo rica e interações explícitas sob a forma de *ratings* [3, 4].

2.4. Recomendação em e-commerce de eletrónica

No domínio do e-commerce, os sistemas de recomendação desempenham um papel fundamental na melhoria da experiência do utilizador e no aumento das taxas de conversão. A grande quantidade de produtos disponíveis torna essencial a utilização de mecanismos automáticos capazes de filtrar e sugerir itens relevantes [5].

Em particular, no contexto de produtos eletrónicos, a diversidade de características técnicas e a rápida evolução do mercado tornam ainda mais complexa a tarefa de recomendação. Neste domínio, recomendações eficazes devem considerar não apenas o comportamento dos utilizadores, mas também a estrutura e o conteúdo dos produtos.

Outro aspeto relevante é a utilização de reviews textuais. Para além do rating numérico, estas reviews fornecem informação semântica rica sobre a experiência do utilizador, contribuindo para uma melhor compreensão das preferências individuais e permitindo melhorar significativamente a qualidade das recomendações [6].

2.5. Enquadramento do presente projeto

O dataset utilizado neste projeto integra informação relativa a utilizadores, produtos e respetivas avaliações, incluindo atributos demográficos, preços, descrições, categorias e conteúdo textual das reviews. Esta diversidade de informação permite retirar duas conclusões relevantes.

Por um lado, a utilização de uma baseline não personalizada constitui um ponto de partida adequado, dada a sua simplicidade, interpretabilidade e utilidade como referência inicial. Por outro lado, a elevada riqueza de metadata associada aos produtos evidencia o potencial de abordagens baseadas em conteúdo, capazes de explorar informação semântica para gerar recomendações mais informadas.

Deste modo, o estado da arte sustenta a estratégia adotada neste trabalho: iniciar com uma abordagem não personalizada e evoluir para um sistema baseado em conteúdo, mantendo como perspectiva futura a integração de ambas as abordagens num modelo híbrido.

3. Especificação Técnica do Dataset

O dataset utilizado é um conjunto de dados de produtos eletrônicos da Amazon, armazenado num ficheiro CSV e posteriormente importado para uma base de dados SQLite. A importação é realizada através de um script de *seeding*, permitindo transformar os dados tabulares em entidades relacionais adequadas à arquitetura do sistema.

3.1. Estrutura lógica dos dados

A modelação adotada organiza os dados em três entidades principais: **User**, **Product** e **Rating**.

User

A entidade *User* representa os utilizadores do dataset e inclui os seguintes atributos:

- **user_id**: identificador único do utilizador;
- **user_name**: nome do utilizador;
- **user_pass**: password do utilizador;
- **Country**: país;
- **Age**: idade;
- **City**: cidade;
- **Marital_Status**: estado civil.

Product

A entidade *Product* representa os produtos eletrónicos e inclui:

- `product_id`: identificador único do produto;
- `product_name`: nome do produto;
- `category`: categoria do produto;
- `discounted_price`: preço com desconto;
- `actual_price`: preço original;
- `discount_percentage`: percentagem de desconto;
- `rating_count`: número de avaliações;
- `about_product`: descrição textual do produto;
- `img_link`: ligação para imagem;
- `product_link`: ligação para a página do produto.

Rating

A entidade *Rating* representa a interação entre utilizador e produto e inclui:

- `review_id`: identificador da review;
- `product_id`: referência ao produto avaliado;
- `user_id`: referência ao utilizador;
- `rating`: valor numérico da avaliação;
- `review_title`: título da review;
- `review_content`: conteúdo textual da review;
- `Used_Device`: dispositivo utilizado;
- `Day_of_Week`: dia da semana associado ao registo.

3.2. Pré-processamento e integração

A integração do dataset foi realizada com Pandas. O ficheiro CSV é lido e os dados são inseridos nas tabelas da base de dados. Durante este processo foram aplicadas várias etapas de preparação:

- prevenção de duplicados em utilizadores e produtos através da verificação prévia de identificadores existentes;

- conversão de preços, percentagens e ratings para formato numérico;
- tratamento de valores em falta durante o *parsing* de valores para `float`;
- preservação da relação entre utilizadores, produtos e avaliações.

Em particular, foi implementada uma função auxiliar para converter corretamente ratings expressos com formatos diferentes, incluindo valores com vírgulas ou percentagens. Esta etapa foi importante para garantir coerência nos dados importados e robustez no carregamento do dataset.

3.3. Adequação do dataset ao problema

O dataset é adequado ao problema por três motivos principais. Em primeiro lugar, contém informação explícita de avaliação, útil para análise de popularidade e para futura personalização. Em segundo lugar, disponibiliza descrição textual e categoria dos produtos, essenciais para um recomendador baseado em conteúdo. Em terceiro lugar, inclui atributos numéricos complementares, como preço, desconto e contagem de ratings, que podem ser usados como sinais auxiliares no ranking dos itens.

4. Arquitetura do Sistema

O sistema foi desenvolvido segundo uma arquitetura modular cliente-servidor, composta por base de dados, backend e frontend. Esta separação de responsabilidades facilita a manutenção, a extensibilidade e a evolução futura do projeto.

4.1. Visão geral da arquitetura

A Figura 1 apresenta a arquitetura do sistema.




Figura 1: Arquitetura do sistema

4.2. Camada de persistência

A camada de persistência é suportada por uma base de dados SQLite, adequada a um contexto académico e prototípico devido à sua simplicidade de configuração e integração local. A modelação relacional é definida com SQLAlchemy, que permite mapear as entidades *User*, *Product* e *Rating* para tabelas físicas.

A criação das tabelas é realizada através do módulo `database.py`, usando `Base.metadata.create_all()`. Esta abordagem garante que a estrutura de dados fica disponível antes da execução do processo de integração e da API.

4.3. Camada de integração de dados

A importação inicial do dataset é realizada pelo módulo `seed.py`. Este script lê o ficheiro CSV, converte os dados e insere-os na base de dados. A importação é efetuada em três blocos: produtos, utilizadores e ratings. Esta separação melhora a organização do processo e reduz o risco de inconsistências.

Além disso, a importação evita duplicação de produtos e utilizadores, uma vez que os identificadores já existentes são verificados antes da inserção. O tratamento específico dos ratings permite também lidar com valores inválidos ou ausentes.

4.4. Camada de serviços Web API

O backend é implementado com FastAPI. Esta framework foi escolhida pela sua simplicidade, bom desempenho, geração automática de documentação e adequação a arquiteturas baseadas em serviços REST.

A aplicação define um conjunto inicial de endpoints para manipulação de utilizadores, produtos e recomendações. A ligação à base de dados é gerida através de uma dependência `get_db()`, que assegura a abertura e fecho correto das sessões. Foi ainda ativado CORS, permitindo que o frontend aceda à API a partir de uma origem distinta.

4.5. Camada de apresentação

O frontend consiste numa página HTML simples com JavaScript, cuja função principal é solicitar recomendações ao endpoint correspondente e apresentar os resultados ao utilizador. Embora minimalista, esta interface permite validar o funcionamento completo do sistema, desde a base de dados até à visualização final.

4.6. Justificação da arquitetura

A arquitetura adotada é adequada aos objetivos do projeto por três razões. Em primeiro lugar, desacopla persistência, lógica de negócio e apresentação. Em segundo lugar, facilita a substituição ou evolução de componentes sem necessidade de alterar toda a aplicação. Em terceiro lugar, permite integrar facilmente novos módulos de recomendação, como um sistema híbrido numa fase futura.

5. Sistema de Recomendação Não Personalizado

A baseline implementada neste projeto corresponde a um sistema de recomendação não personalizado. Neste tipo de abordagem, todos os utilizadores recebem essencialmente a mesma lista de itens recomendados, independentemente do seu histórico individual.

5.1. Motivação da baseline

A utilização de uma baseline não personalizada é importante por duas razões. Em primeiro lugar, fornece um ponto de comparação simples e interpretável para abordagens mais

sofisticadas. Em segundo lugar, permite gerar recomendações mesmo na ausência de perfil individual, o que é útil em cenários de *cold start* do utilizador [1].

5.2. Critério de ranking

A lógica da baseline baseia-se na popularidade global dos produtos. Em termos conceituais, o objetivo é identificar os itens com maior evidência de aceitação agregada. Num contexto coerente com o dataset, este ranking pode apoiar-se em sinais como:

- número total de avaliações do produto;
- média de rating do produto;
- combinação entre média de rating e volume de avaliações.

Uma formulação simples para o score de popularidade é dada por:

$$score(p) = count(p) \tag{1}$$

onde $count(p)$ representa o número de interações ou avaliações observadas para o produto p .

Uma alternativa ligeiramente mais informativa consiste em ponderar a média de rating pelo número de avaliações:

$$score(p) = \bar{r}_p \times \log(1 + count(p)) \tag{2}$$

onde $\bar{r}_p$ representa a média de ratings do produto p .

5.3. Vantagens e limitações

A baseline não personalizada apresenta as seguintes vantagens:

- simplicidade de implementação;
- baixo custo computacional;
- elevada interpretabilidade;
- aplicabilidade imediata mesmo sem perfil do utilizador.

No entanto, também apresenta limitações evidentes:

- ausência de personalização;

- tendência para privilegiar itens muito populares;
- menor diversidade e menor adequação a preferências individuais.

Estas limitações justificam a comparação com um método baseado em conteúdo, que procura incorporar informação semântica dos produtos.

6. Sistema de Recomendação Baseado em Conteúdo

O sistema baseado em conteúdo procura recomendar produtos semelhantes com base nas suas características descritivas e estruturais. Esta abordagem é especialmente apropriada para o dataset em causa, dado que os produtos dispõem de metadados ricos, incluindo nome, categoria e descrição textual [2].

6.1. Representação dos produtos

Cada produto pode ser representado por um conjunto de atributos, dos quais se destacam:

- `product_name`;
- `category`;
- `about_product`;
- atributos numéricos auxiliares, como `discounted_price`, `actual_price` e `discount_percentage`.

No contexto deste projeto, a representação baseada em conteúdo centra-se sobretudo na componente textual. Para isso, os campos textuais podem ser concatenados e transformados num vetor num espaço de características.

6.2. Vetorização com TF-IDF

Para transformar texto em representação numérica, uma técnica clássica e interpretável é o TF-IDF (*Term Frequency – Inverse Document Frequency*). Esta técnica atribui maior peso a termos frequentes num documento, mas menos comuns no conjunto total de documentos.

A ponderação TF-IDF de um termo t num documento d pode ser expressa por:

$$TF\text{-}IDF(t, d) = TF(t, d) \times \log \left(\frac{N}{df(t)} \right) \quad (3)$$

onde $TF(t, d)$ é a frequência do termo t no documento d , N é o número total de documentos e $df(t)$ é o número de documentos que contêm o termo t .

Ao utilizar esta representação conseguimos verificar a semelhança entre descrições de produtos.

6.3. Cálculo de similaridade

Uma vez obtidos os vetores dos produtos, a proximidade entre dois itens pode ser calculada através da similaridade do cosseno. Para dois vetores A e B , esta medida é dada por:

$$\text{sim}(A, B) = \frac{A \cdot B}{\|A\| \|B\|} \quad (4)$$

Valores mais elevados indicam maior semelhança entre os produtos comparados. Em termos práticos, para um produto de referência, os itens com maior valor de similaridade são selecionados como recomendação.

6.4. Papel da categoria e das subcategorias

No dataset utilizado, a variável `category` é particularmente relevante, porque ajuda a restringir a comparação entre itens semanticamente próximos. Mesmo quando a estrutura está condensada num único campo, esta variável pode refletir subcategorias ou agrupamentos internos dos produtos. Assim, torna-se possível distinguir produtos pertencentes a segmentos distintos da eletrónica e reduzir recomendações irrelevantes.

Esta utilização das categorias e subcategorias implícitas melhora a coerência das recomendações e reforça a adequação da abordagem baseada em conteúdo ao domínio selecionado.

6.5. Construção do perfil do utilizador

Num sistema baseado em conteúdo, o perfil do utilizador pode ser obtido a partir dos produtos que avaliou positivamente. Em termos simplificados, o perfil pode ser representado pela média dos vetores correspondentes aos itens preferidos:

$$\vec{u} = \frac{1}{|I_u|} \sum_{i \in I_u} \vec{i} \quad (5)$$

onde I_u representa o conjunto de itens relevantes para o utilizador u e $\vec{i}$ o vetor do item i .

Depois de construído o perfil, as recomendações são obtidas ordenando os produtos pela sua similaridade em relação ao vetor do utilizador.

6.6. Vantagens e limitações

As principais vantagens da abordagem baseada em conteúdo são:

- personalização das recomendações;
- menor dependência de outros utilizadores;
- adequação a domínios com metadata rica.

As principais limitações incluem:

- dependência da qualidade das descrições textuais;
- risco de baixa diversidade;
- dificuldade em recomendar itens muito diferentes dos já observados no perfil.

Apesar destas limitações, a abordagem baseada em conteúdo é particularmente apropriada para este projeto, dada a estrutura do dataset e a riqueza descritiva dos produtos.

7. Filtragem Colaborativa

7.1. Princípio de funcionamento

A filtragem colaborativa baseia-se na premissa de que utilizadores com comportamentos semelhantes no passado tendem a ter preferências semelhantes no futuro. Ao contrário da abordagem baseada em conteúdo, este método não utiliza os atributos dos produtos, mas sim os padrões de interação entre utilizadores e itens. Neste projecto foram implementadas duas variantes: filtragem colaborativa baseada em utilizadores (*user-based*) e filtragem colaborativa baseada em itens (*item-based*).

7.2. Implementação

A implementação da filtragem colaborativa seguiu uma estrutura comum às duas variantes. Numa primeira fase, os dados de ratings foram divididos em conjuntos de treino e teste através de uma estratégia por utilizador: para cada utilizador com dois ou mais ratings, um registo foi reservado para teste, sendo os restantes utilizados para treino. Esta abordagem garante que todos os utilizadores presentes no conjunto de teste têm histórico disponível no conjunto de treino.

A partir dos dados de treino foi construída uma matriz utilizador-item $R \in \mathbb{R}^{|U| \times |I|}$, onde as linhas representam utilizadores, as colunas representam produtos e os valores correspondem aos ratings atribuídos. As células sem interação foram preenchidas com zero para efeitos de cálculo de similaridade.

No modelo *item-based*, a similaridade entre dois produtos i e j foi calculada aplicando a similaridade do cosseno à transposta da matriz utilizador-item:

$$\text{sim}(i, j) = \frac{\vec{r}_i \cdot \vec{r}_j}{\|\vec{r}_i\| \|\vec{r}_j\|} \quad (6)$$

onde $\vec{r}_i$ representa o vector de ratings do produto i sobre todos os utilizadores. Para gerar recomendações, o sistema agrega os scores de similaridade com os restantes produtos ponderados pelo rating atribuído pelo utilizador:

$$\text{score}(u, j) = \sum_{i \in I_u} \text{sim}(i, j) \times r_{u,i} \quad (7)$$

onde I_u é o conjunto de produtos avaliados pelo utilizador u e $r_{u,i}$ o rating que u atribuiu ao produto i . Os produtos com score mais elevado são devolvidos, excluindo os já avaliados.

No modelo *user-based*, foi aplicado *mean-centering* antes do cálculo da similaridade, subtraindo a cada utilizador u a média dos seus próprios ratings $\bar{r}_u$:

$$\tilde{r}_{u,i} = r_{u,i} - \bar{r}_u \quad (8)$$

de forma a reduzir o enviesamento causado por utilizadores que atribuem sistematicamente ratings altos ou baixos. A similaridade do cosseno foi então calculada sobre esta matriz centrada $\tilde{R}$. A previsão do rating do utilizador u para o produto p é dada por:

$$\hat{r}_{u,p} = \frac{\sum_{v \in N(u)} \text{sim}(u, v) \times r_{v,p}}{\sum_{v \in N(u)} |\text{sim}(u, v)|} \quad (9)$$

onde $N(u)$ representa os k utilizadores mais similares a u que avaliaram o produto p . A avaliação foi realizada com recurso às métricas RMSE e Hit Rate@K.

7.3. Vantagens e Limitações

As principais vantagens da filtragem colaborativa são a capacidade de capturar preferências implícitas sem depender dos atributos dos produtos e a adequação a domínios com histórico de interações rico. O modelo *item-based* apresenta ainda maior estabilidade do que o *user-based*, uma vez que os padrões de consumo de produtos tendem a ser mais consistentes do que os perfis individuais dos utilizadores.

As principais limitações incluem o problema de *cold start* tanto para utilizadores novos, que não possuem histórico suficiente para calcular similaridades, como para produtos novos, que não foram ainda avaliados por nenhum utilizador. Adicionalmente, a qualidade das recomendações é directamente dependente do volume e da densidade das interações

disponíveis, tornando este tipo de abordagem mais eficaz em datasets com múltiplos ratings por utilizador.

8. Sistema de Recomendação Baseado em Conhecimento

8.1. Princípio de funcionamento

Os sistemas de recomendação baseados em conhecimento distinguem-se das abordagens anteriores por não dependerem do histórico de interações dos utilizadores. Em vez disso, as recomendações são geradas com base em restrições e regras explícitas, definidas a partir do conhecimento do domínio e das preferências declaradas pelo utilizador. Esta característica torna-os particularmente adequados em cenários de *cold start*, onde não existe histórico suficiente para aplicar filtragem colaborativa ou baseada em conteúdo.

No contexto deste projecto, o sistema recebe um conjunto de restrições fornecidas pelo utilizador — como categoria de produto, preço máximo, rating mínimo ou desconto mínimo — e devolve os produtos que satisfazem essas restrições, ordenados por um score de popularidade ponderado.

8.2. Implementação

A implementação seguiu uma abordagem de filtragem por restrições combinada com regras demográficas automáticas.

Numa primeira fase, o dataset de produtos foi preparado com a conversão dos atributos numéricos relevantes — preço, desconto, rating médio e número de avaliações — para formato numérico. Foi também extraída a categoria principal de cada produto a partir do primeiro nível da hierarquia de categorias. Por fim, foi calculado um score de popularidade para cada produto, definido como o produto entre o rating médio e o logaritmo do número de avaliações:

$$\text{popularity_score}(p) = \bar{r}_p \times \log(1 + \text{count}(p)) \quad (10)$$

onde $\bar{r}_p$ representa o rating médio do produto p e $\text{count}(p)$ o número total de avaliações recebidas. Esta formulação privilegia produtos com rating elevado e volume expressivo de avaliações, penalizando itens com poucas interações independentemente do seu rating.

Numa segunda fase, a função de recomendação aplica sequencialmente as restrições fornecidas pelo utilizador:

$$\mathcal{F}(P) = \{ p \in P \mid \text{cat}(p) = c \wedge \text{price}(p) \leq p_{\max} \wedge \bar{r}_p \geq r_{\min} \wedge \text{disc}(p) \geq d_{\min} \wedge \text{count}(p) \geq n_{\min} \} \quad (11)$$

onde P é o conjunto total de produtos, c a categoria seleccionada, $p_{\max}$ o preço máximo, $r_{\min}$ o rating mínimo, $d_{\min}$ o desconto mínimo e $n_{\min}$ o número mínimo de avaliações. As restrições não fornecidas pelo utilizador são ignoradas. Os produtos em $\mathcal{F}(P)$ são ordenados pelo score de popularidade e os n primeiros são devolvidos como recomendação.

Adicionalmente, foram implementadas regras demográficas automáticas que ajustam as restrições com base no perfil do utilizador. Utilizadores com idade igual ou inferior a 30 anos têm um desconto mínimo de 20% aplicado automaticamente, reflectindo uma maior sensibilidade ao preço neste segmento. Utilizadores que acedem ao sistema através de dispositivo móvel são redireccionados para a categoria de acessórios e periféricos, por maior afinidade com esse tipo de produtos. Em situações de *budget* reduzido, a ordenação é feita pelo desconto em vez do score de popularidade, priorizando os produtos com maior redução de preço.

8.3. Vantagens e Limitações

A principal vantagem deste tipo de sistema é a total independência do histórico de interações, permitindo gerar recomendações úteis mesmo para utilizadores novos. A interpretabilidade é também um ponto forte: as recomendações resultam directamente de regras explícitas, o que facilita a justificação das sugestões apresentadas ao utilizador. A incorporação de regras demográficas permite ainda uma personalização básica sem necessidade de dados comportamentais.

As principais limitações residem na dependência da qualidade e completude das restrições fornecidas pelo utilizador — restrições demasiado restritivas podem resultar em listas vazias — e na ausência de personalização profunda, uma vez que dois utilizadores com as mesmas restrições recebem exactamente as mesmas recomendações.

9. Sistema de Recomendação Híbrido

9.1. Princípio de funcionamento

O sistema híbrido implementado neste projecto combina as três abordagens anteriores: recomendação não personalizada, filtragem baseada em conteúdo e filtragem colaborativa, numa única resposta apresentada ao utilizador. A estratégia adoptada corresponde a uma *hibridização do tipo mixed hybrid*: em vez de combinar os *scores* dos diferentes modelos numa pontuação única, cada modelo contribui com um conjunto independente

de recomendações, apresentadas simultaneamente ao utilizador com explicações distintas sobre a origem de cada sugestão.

9.2. Implementação

A resposta do sistema híbrido é composta por três segmentos, cada um alimentado por um modelo diferente, com dimensões configuráveis $(n_{\text{top}}, n_{\text{cbf}}, n_{\text{cf}})$, tal que o número total de recomendações devolvidas é:

$$n_{\text{total}} = n_{\text{top}} + n_{\text{cbf}} + n_{\text{cf}} \quad (12)$$

- O primeiro segmento contém n_{top} produtos recomendados pelo sistema não personalizado, seleccionados a partir de um *pool* de produtos pré-calculado e ordenado por *rating* médio. Estes produtos são apresentados com a indicação do *rating* médio e são comuns a todos os utilizadores.
- O segundo segmento contém n_{cbf} recomendações geradas pelo modelo de filtragem baseada em conteúdo, a partir dos produtos que o utilizador avaliou. Para cada produto recomendado j , o sistema identifica o produto avaliado i^* que mais contribuiu para aquela sugestão:

$$i^* = \arg \max_{i \in I_u} \text{sim}(i, j) \quad (13)$$

onde I_u é o conjunto de produtos avaliados pelo utilizador u e $\text{sim}(i, j)$ a similaridade do cosseno entre os produtos i e j . Este produto é utilizado para gerar a explicação apresentada ao utilizador, do tipo “*Because you liked [produto]*”. Este segmento requer que o utilizador tenha pelo menos um *rating* registado.

- O terceiro segmento contém n_{cf} recomendações geradas pela filtragem colaborativa. O sistema tenta primeiro o modelo *user-based*; caso não produza resultados, recorre ao modelo *item-based* como alternativa. As recomendações deste segmento são apresentadas com a explicação “*Users with similar taste also liked this*”. Este segmento requer que o utilizador tenha pelo menos dois *ratings* registados.

Em todos os segmentos é garantida a ausência de duplicados através de um conjunto S de produtos já seleccionados, actualizado a cada adição:

$$S \leftarrow S \cup \{j\}, \quad \forall j \text{ adicionado à resposta} \quad (14)$$

Quando um modelo não consegue gerar recomendações suficientes, o sistema completa o segmento com produtos do *pool* não personalizado, assegurando que a resposta tem sempre n_{total} itens.

O sistema é exposto através do *endpoint* `/recommendations/hybrid/{user_id}` da Web API, que devolve a lista completa de recomendações com os campos `product_id`, `product_name`, `category`, `discounted_price`, `avg_rating`, `source` e `explanation`.

9.3. Vantagens e Limitações

A principal vantagem desta abordagem é a capacidade de servir qualquer utilizador, independentemente do seu histórico, através do mecanismo de *fallback* para recomendações não personalizadas. A apresentação de recomendações de origens distintas aumenta também a diversidade dos resultados e a transparência do sistema, uma vez que cada sugestão inclui uma explicação sobre o motivo pelo qual foi gerada. A arquitectura modular facilita ainda a adição de novos modelos sem alterar a estrutura geral da resposta.

A principal limitação é a ausência de uma função de combinação de *scores*, o que impede uma ordenação global óptima entre os produtos dos diferentes segmentos. Adicionalmente, a qualidade do segmento colaborativo permanece dependente do volume de *ratings* disponíveis por utilizador.

10. Cold Start de Utilizadores

O problema de *cold start* de utilizadores ocorre quando um novo utilizador se regista no sistema sem qualquer histórico de interações, impossibilitando a aplicação de modelos personalizados como a filtragem baseada em conteúdo ou a filtragem colaborativa.

A estratégia adoptada neste projecto tira partido da arquitectura do sistema híbrido, que integra nativamente um mecanismo de *fallback* progressivo em função do número de *ratings* do utilizador. Para um utilizador sem nenhum *rating*, os três segmentos da resposta híbrida são preenchidos com recomendações não personalizadas, baseadas nos produtos com maior *rating* médio global. As mensagens de explicação informam o utilizador de que pode desbloquear recomendações personalizadas ao avaliar produtos — “*Rate some products to unlock personalised recommendations*”.

À medida que o utilizador acumula *ratings*, o sistema evolui progressivamente: com um *rating* registado, o segundo segmento passa a ser preenchido pelo modelo de filtragem baseada em conteúdo, e o utilizador recebe a indicação de que um *rating* adicional permite activar as recomendações colaborativas — “*Rate 1 more product to unlock personalised CF recommendations*”. Com dois ou mais *ratings*, o sistema híbrido completo fica disponível, incluindo o segmento colaborativo.

Esta abordagem resolve o *cold start* de utilizadores sem requerer qualquer informação demográfica prévia, baseando-se exclusivamente no comportamento de *rating* progressivo do utilizador.

11. Cold Start de Itens

O problema de *cold start* de itens ocorre quando um novo produto é adicionado ao catálogo sem ter ainda recebido nenhuma avaliação, tornando-o invisível para modelos baseados em *ratings* como a filtragem colaborativa.

A estratégia adoptada neste projecto recorre ao modelo de filtragem baseada em conteúdo para mitigar este problema. Uma vez que o modelo CBF representa cada produto exclusivamente através dos seus atributos — categoria, nome, descrição e preço — e não depende de *ratings* históricos, um produto novo fica imediatamente disponível para recomendação desde que possua os campos de *metadata* preenchidos. O novo item pode ser recomendado como produto similar a outros que o utilizador tenha avaliado, com base na sua proximidade no espaço de características.

O modelo colaborativo, por sua vez, só passa a incluir o novo produto nas suas recomendações após acumular *ratings* suficientes para estabelecer similaridades com outros itens ou utilizadores. Até esse momento, o CBF actua como mecanismo de cobertura, garantindo que novos produtos têm oportunidade de exposição no sistema.

12. Avaliação dos Modelos de Recomendação

Esta secção descreve a metodologia de avaliação aplicada ao conjunto de modelos implementados, apresenta os resultados obtidos e discute o desempenho comparativo entre as diferentes abordagens.

12.1. Estratégia de avaliação

A avaliação foi conduzida segundo um esquema *leave-one-out* por utilizador: para cada utilizador com pelo menos dois ratings, um item foi reservado aleatoriamente para o conjunto de teste (*held-out item*), ficando os restantes disponíveis para construção do perfil de treino. Utilizadores com apenas um rating foram excluídos do conjunto de teste, uma vez que não é possível construir um perfil mínimo e reservar simultaneamente um item para validação.

O conjunto de dados é composto por 5858 avaliações distribuídas por 1194 utilizadores. Após a divisão, 4667 avaliações integram o treino e 1191 o teste, correspondendo a 1191 utilizadores com pelo menos um item reservado. Nenhum utilizador de teste ficou sem histórico de treino, garantindo que todos os modelos dispõem de informação mínima para gerar recomendações.

Para cada utilizador de teste, cada modelo gera uma lista ordenada dos top- K itens recomendados, excluindo os itens já avaliados em treino. Verifica-se de seguida se o *held-*

out item figura nos primeiros K lugares dessa lista.

12.2. Métricas de avaliação

Precision@K

A métrica principal utilizada é a **Precision@K**, que mede a proporção de itens recomendados no top- K que são relevantes para o utilizador:

$$\text{Precision@K} = \frac{|Rel_u \cap Rec_u(K)|}{|Rec_u(K)|} \quad (15)$$

onde Rel_u é o conjunto de itens relevantes para o utilizador u e $Rec_u(K)$ representa o conjunto dos K itens recomendados.

Nesta configuração experimental, com um único *held-out item* por utilizador, a Recall@K colapsa para a Hit Rate binária — indica apenas se o item foi ou não recuperado, sem distinguir a qualidade da lista para diferentes valores de K . A Precision@K, ao dividir pelo tamanho da lista, penaliza listas maiores e mede diretamente a eficiência dos slots de recomendação disponíveis, sendo por isso a métrica preferida.

RMSE

O *Root Mean Squared Error* avalia a precisão na estimativa do valor numérico do rating, sendo calculado para os modelos que produzem explicitamente uma previsão de classificação:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{r}_i - r_i)^2} \quad (16)$$

onde $\hat{r}_i$ é o rating previsto e r_i o rating real observado. Para cada modelo, a previsão de rating é obtida da seguinte forma:

- **CF baseado em item:** média ponderada dos ratings do utilizador para itens similares, usando a similaridade item-item como peso;
- **CF baseado em utilizador:** média ponderada dos ratings de utilizadores similares para o item em causa;
- **Baseline não personalizada:** média global do item calculada sobre o conjunto de treino;

- **Baseado em conteúdo:** média ponderada dos ratings do utilizador, usando a similaridade de conteúdo entre o item a prever e os itens avaliados como peso.

Os modelos híbridos não produzem uma estimativa de rating independente — o seu output é uma lista ordenada obtida por combinação dos modelos base — pelo que o RMSE não é calculado para estas abordagens.

12.3. Resultados

A Tabela 1 sintetiza os resultados obtidos para todos os modelos avaliados, com $K \in \{5, 10, 20\}$.

Tabela 1: Resultados de avaliação — Precision@K e RMSE (1191 utilizadores de teste)

Modelo	P@5	P@10	P@20	RMSE
Baseline (Não Personalizada)	0,0000	0,0000	0,0000	0,6800
Baseado em Conteúdo	0,0097	0,0064	0,0045	0,6921
CF Baseado em Item	0,0366	0,0191	0,0099	0,8096
CF Baseado em Utilizador	0,0065	0,0047	0,0027	0,8217
Híbrido por Comutação	0,0072	0,0050	0,0029	—
Híbrido Misto	0,0082	0,0225	0,0113	—
Híbrido Ponderado	0,0044	0,0036	0,0026	—
Híbrido em Cascata	0,0002	0,0001	0,0000	—

12.4. Discussão

Baseline não personalizada

A baseline apresenta o melhor RMSE do conjunto (0,6800), refletindo a capacidade de estimar ratings médios com precisão. Contudo, a Precision@K é nula em todos os valores de K testados. Este aparente paradoxo explica-se pelo facto de a baseline recomendar os produtos com maior rating médio global a todos os utilizadores: embora as estimativas de rating sejam boas em termos absolutos, a lista gerada não é personalizada e raramente coincide com o item específico reservado por cada utilizador. A baseline constitui, assim, um ponto de partida útil como referência e para cenários de cold-start, mas não produz recomendações relevantes numa avaliação personalizada.

Filtragem baseada em conteúdo

O modelo baseado em conteúdo apresenta Precision@K superior à baseline em todos os valores de K ($P@5 = 0,0097$), confirmando que a exploração de atributos semânticos dos

produtos — categoria, descrição e nome — introduz personalização efetiva. O RMSE (0,6921) é ligeiramente superior ao da baseline, o que se deve ao facto de a média ponderada por similaridade poder introduzir desvio na escala absoluta do rating quando a similaridade entre itens é baixa. Este custo é compensado pela melhoria na qualidade do ranking.

Filtragem colaborativa

O CF baseado em item obtém os melhores resultados de Precision@K para K pequeno ($P@5 = 0,0366$), superando todos os outros modelos nesse regime. Este resultado é consistente com a natureza do modelo, que explora correlações diretas entre itens avaliados pelo mesmo utilizador. O RMSE (0,8096) é superior ao dos modelos anteriores, refletindo a dificuldade de estimar ratings exatos num dataset esparso.

O CF baseado em utilizador apresenta desempenho substancialmente inferior, tanto em Precision@K ($P@5 = 0,0065$) como em RMSE (0,8217). A esparsidade do dataset — em média 4 ratings por utilizador após a divisão treino/teste — implica que a maioria dos pares de utilizadores não partilha itens avaliados em comum, tornando a similaridade utilizador-utilizador pouco fiável.

Modelos híbridos

O *mixed hybrid* obtém os melhores resultados globais para $K \geq 10$ ($P@10 = 0,0225$, $P@20 = 0,0113$), superando todos os modelos individuais. Este modelo combina explicitamente itens da baseline, do CBF e do CF colaborativo por item, equilibrando cobertura e personalização. A desvantagem observada em $P@5$ (0,0082, inferior ao CF por item) deve-se ao facto de os itens da baseline serem inseridos no início da lista, ocupando slots que de outra forma seriam preenchidos por itens colaborativos mais precisos para listas curtas.

O *switching hybrid* ($P@5 = 0,0072$) apresenta desempenho próximo do CF por utilizador, uma vez que 99,7% dos utilizadores de teste possuem histórico suficiente para acionar o ramo colaborativo, mas a esparsidade limita a qualidade desse ramo.

O *weighted hybrid* ($P@5 = 0,0044$) fica abaixo do CF por item isolado, indicando que a normalização e combinação linear dos scores dilui o sinal colaborativo em vez de o amplificar.

O *cascade hybrid* apresenta os piores resultados de todo o conjunto ($P@5 \approx 0,0002$), o que sugere que o funil de filtragem progressivo (baseline $\rightarrow$ CBF $\rightarrow$ CF) descarta o *held-out item* antes da etapa de re-ranking final, sobretudo devido a dimensões de pool demasiado restritivas.

Síntese comparativa

Os resultados permitem identificar dois padrões distintos. Para listas curtas ($K = 5$), o CF baseado em item é a opção mais eficiente. Para listas mais longas ($K \geq 10$), o híbrido misto supera todos os modelos. A baseline mantém utilidade prática em contextos de *cold-start* e como referência, mas não deve ser utilizada como estratégia de ranking personalizado.

Em termos de estimativa de rating, os modelos não colaborativos (baseline e CBF) apresentam RMSE mais baixo, o que evidencia que a qualidade do ranking e a precisão de rating são objetivos distintos que podem não estar correlacionados.

12.5. Limitações da avaliação

1. **Esparsidade elevada** — Com uma média de aproximadamente 4 ratings por utilizador após a divisão, a maioria dos pares utilizador-item permanece desconhecida, prejudicando sobretudo os modelos colaborativos.
2. **Avaliação com item único** — O esquema *leave-one-out* reserva um único item por utilizador. Nesta configuração, a Precision@K equivale à Hit Rate dividida por K , e os valores absolutos são necessariamente baixos. Uma avaliação com múltiplos itens reservados ou com divisão temporal produziria resultados mais robustos.
3. **Avaliação offline vs. online** — As métricas offline medem apenas se o item reservado foi recuperado. Não capturam satisfação, novidade ou serendipidade. Um teste A/B seria necessário para medir o impacto real no comportamento do utilizador.
4. **Qualidade das *features* de conteúdo** — A representação TF-IDF trata expressões semanticamente equivalentes como tokens distintos (e.g., “USB-C cable” e “Type-C cable”). O uso de *embeddings* de modelos de linguagem melhoraria significativamente a qualidade do CBF.
5. **Ausência de ordenação temporal** — Todas as avaliações são tratadas com igual peso independentemente da sua data. Um modelo com ponderação de recência reflectiria melhor as preferências actuais.

12.6. Discussão

A análise comparativa dos oito modelos avaliados permite concluir que diferentes abordagens se destacam em diferentes regimes de avaliação, não existindo um modelo universalmente superior em todas as métricas.

A baseline não personalizada, apesar de registar o melhor RMSE (0.6800), obteve Precision@K e Recall@K nulos para todos os valores de K , confirmando que a popularidade global não constitui um predictor eficaz de preferências individuais. Este resultado justifica a necessidade de introduzir personalização no sistema.

O modelo baseado em conteúdo revelou-se uma melhoria consistente face à baseline em termos de ranking, demonstrando que a exploração dos atributos dos produtos introduz personalização efectiva mesmo com histórico reduzido. O Item-Based CF destacou-se como o modelo individual mais eficaz, atingindo P@5 de 0.0366 e R@5 de 0.1830, superando todos os restantes modelos a K pequeno.

Entre as abordagens híbridas, o Mixed Hybrid obteve os melhores resultados a $K \geq 10$, com P@10 de 0.0225 e R@10 de 0.2250, evidenciando que a combinação de múltiplas fontes de recomendação numa resposta diversificada aumenta a cobertura e a qualidade das sugestões para listas de maior dimensão. O Cascade Hybrid apresentou os resultados mais fracos, sugerindo que o mecanismo de filtragem progressiva elimina itens relevantes antes da fase final de ordenação, sendo necessário um ajuste cuidadoso dos tamanhos dos pools intermédios.

Observa-se ainda uma tensão entre RMSE e Precision@K que merece destaque: os modelos com menor RMSE não são necessariamente os mais eficazes na recuperação de itens relevantes. Esta dicotomia reflecte a diferença entre precisão de previsão de rating e qualidade de ranking, sendo esta última a dimensão mais relevante para a experiência do utilizador final.

13. Conclusão

O presente relatório descreveu o desenvolvimento de um sistema de recomendação híbrido aplicado ao domínio de produtos electrónicos, recorrendo ao dataset Amazon Electronics. O sistema integra quatro abordagens complementares: recomendação não personalizada, filtragem baseada em conteúdo, filtragem colaborativa e recomendação baseada em conhecimento combinadas numa arquitectura híbrida do tipo *mixed hybrid*, suportada por uma arquitectura cliente-servidor com base de dados relacional, backend em FastAPI e frontend web.

Do ponto de vista técnico, a implementação abrangeu a construção de modelos distintos, cada um com características e adequações específicas ao domínio. A filtragem baseada em conteúdo explorou atributos como nome, categoria, descrição e preço dos produtos para calcular similaridades entre itens. A filtragem colaborativa, nas suas variantes *item-based* e *user-based*, tirou partido dos padrões de rating entre utilizadores. O sistema baseado em conhecimento permitiu gerar recomendações através de restrições explícitas e regras demográficas, sem depender de histórico de interações. O sistema híbrido combinou estas

abordagens numa resposta única e transparente, com mecanismos de *fallback* progressivo para tratar o problema de *cold start*.

A avaliação experimental, conduzida sobre 1191 utilizadores de teste com as métricas Precision@K, Recall@K e RMSE, revelou que o Item-Based CF é o modelo individual mais eficaz a K pequeno, enquanto o Mixed Hybrid se destaca a $K \geq 10$. A baseline não personalizada, apesar do melhor RMSE, obteve Precision@K e Recall@K nulos, confirmando a necessidade de personalização.

Referências

- [1] G. Adomavicius and A. Tuzhilin, *Toward the Next Generation of Recommender Systems: A Survey of the State-of-the-Art and Possible Extensions*, IEEE Transactions on Knowledge and Data Engineering, vol. 17, no. 6, pp. 734–749, 2005.
- [2] P. Lops, M. de Gemmis and G. Semeraro, *Content-based Recommender Systems: State of the Art and Trends*, in Recommender Systems Handbook, Springer, 2011, pp. 73–105.
- [3] R. Burke, *Hybrid Recommender Systems: Survey and Experiments*, User Modeling and User-Adapted Interaction, vol. 12, pp. 331–370, 2002.
- [4] F. Ricci, L. Rokach and B. Shapira, *Recommender Systems: Techniques, Applications, and Challenges*, in Recommender Systems Handbook, 3rd ed., Springer, 2022.
- [5] ACM, Product Recommendation in E-commerce Systems, 2025.
- [6] J. McAuley et al., Leveraging Reviews in Recommendation Systems, ACM, 2017.
- [7] Jain et al., A Survey on Recommender Systems: Challenges and Advances, Journal of Big Data, 2022.